

#### МИНОБРНАУКИ РОССИИ

Федеральное государственное бюджетное образовательное учреждение высшего образования

# «МИРЭА – Российский технологический университет» РТУ МИРЭА

ИКБ направление «Киберразведка и противодействие угрозам с применением технологий искусственного интеллекта» 10.04.01

Кафедра КБ-4 «Интеллектуальные системы информационной безопасности»

### Лабораторная работа № 1

по дисциплине «Анализ защищенности систем искусственного интеллекта»

Выполнила: Котюкова В.О.

Проверил: Спирин А.А.

Скопируем проект в локальную среду выполнения.

```
[ ] !git clone https://github.com/ewatson2/EEL6812_DeepFool_Project.git
fatal: destination path 'EEL6812_DeepFool_Project' already exists and is not an empty directory.
```

Сменим директорию исполнения на вновь созданную папку "EEL6812\_DeepFool\_Project" проекта.

```
[ ] %cd /content/EEL6812_DeepFool_Project
/content/EEL6812_DeepFool_Project
```

Выполним импорт стандартных и вспомогательных библиотек.

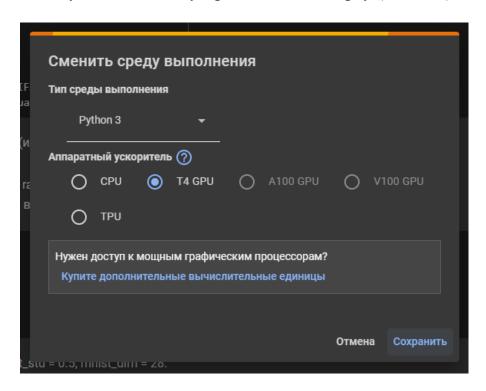
```
[ ] import numpy as np
import os
import json, torch
from torch.utils.data import DataLoader, random_split
from torchvision import datasets, models
from torchvision.transforms import transforms
from models.project_models import FC_500_150, LeNet_CIFAR, LeNet_MNIST, Net
from utils.project_utils import get_clip_bounds, evaluate_attack, display_attack
```

Установим случайное значение в виде переменной rand\_seed={11}. Установим указанное значение для np.random.seed и torch.manual\_seed.

```
[ ] rand_seed = 11
    np.random.seed(rand_seed)
    torch.manual_seed(rand_seed)

    use_cuda = torch.cuda.is_available()
    device = torch.device('cuda' if use_cuda else 'cpu')
```

В работе используем в качестве устройства видеокарту (T4 GPU).



Загрузим датасет MNIST с параметрами mnist\_mean = 0.5, mnist\_std = 0.5, mnist\_dim = 28.

```
mnist_mean = 0.5
mnist_dim = 28

mnist_min mnist_max = get_clip_bounds(mnist_mean, mnist_std, mnist_dim)
mnist_min = mnist_min.to(device)
mnist_max = mnist_max.to(device)
mnist_tf = transforms.Compose([ transforms.ToTensor(), transforms.Normalize( mean=mnist_mean, std=mnist_std)])
mnist_tf_train = transforms.Compose([ transforms.RandomHorizontalFlip(), transforms.ToTensor(), transforms.Normalize( mean=mnist_mean, std=mnist_mean, std=mnist_mean, std=mnist_std)])
mnist_tf_inv = transforms.Compose([ transforms.Normalize( mean=0.0, std=np.divide(1.0, mnist_std)), transforms.Normalize( mean=np.multiply(-1.0, mnist_std)), std=1.0)])
mnist_temp = datasets.MNIST(root='datasets/mnist', train=True, download=True, transform=mnist_tf_train)
mnist_train, mnist_val = random_split(mnist_temp, [50000, 10000])
mnist_test = datasets.MNIST(root='datasets/mnist', train=False, download=True, transform=mnist_tf)
```

Загрузим датасет CIFAR-10 с параметрами cifar\_mean = [0.491, 0.482, 0.447] cifar\_std = [0.202, 0.199, 0.201] cifar\_dim = 32.

```
[] cifar_mean = [0.491, 0.482, 0.447]
cifar_std = [0.282, 0.199, 0.281]
cifar_std = [0.282, 0.199, 0.281]
cifar_min = cifar_max = get_clip_bounds(cifar_mean, cifar_std, cifar_dim)
cifar_min = cifar_min.to(device)
cifar_min = cifar_min.to(device)
cifar_tf = transforms.Compose([ transforms.Normalize( mean-cifar_mean, std-cifar_std)])
cifar_tf_train = transforms.Compose([ transforms.RandomCrop( size-cifar_dim, padding=4), transforms.RandomHorizontalFlip(), transforms.ToTensor(), transforms.Normalize( mean-cifar_mean, std-cifar_std)])
cifar_tf_inv = transforms.Compose([ transforms.Normalize( mean=[0.0, 0.0, 0.0], std=np.divide(1.0, cifar_std)), transforms.Normalize( mean=np.multiply(-1.0, cifar_mean), std=[1.0, 1.0, 1.0])])
cifar_temp = datasets.CIFARIO(root-'datasets/cifar-10', train=True, download=True, transform=cifar_tf_train)
cifar_train, cifar_val = random_split(cifar_temp, [40000, 10000])
cifar_test = datasets.CIFARIO(root-'datasets/cifar-10', train=False, download=True, transform=cifar_tf)
cifar_classes = ['airplane', 'automobile', 'bird', 'cat', 'deer', 'dog', 'frog', 'horse', 'ship', 'truck']

Files already downloaded and verified
```

Выполним настройку и загрузку DataLoader с параметрамми batch\_size = 64 workers = 4.

```
#DataLoader
batch_size = 64
workers = 4
mnist_loader_train = DataLoader(mnist_train, batch_size=batch_size, shuffle=True, num_workers=workers)
mnist_loader_val = DataLoader(mnist_val, batch_size=batch_size, shuffle=False, num_workers=workers)
mnist_loader_test = DataLoader(mnist_test, batch_size=batch_size, shuffle=False, num_workers=workers)
cifar_loader_train = DataLoader(cifar_train, batch_size=batch_size, shuffle=True, num_workers=workers)
cifar_loader_val = DataLoader(cifar_val, batch_size=batch_size, shuffle=False, num_workers=workers)
cifar_loader_test = DataLoader(cifar_test, batch_size=batch_size, shuffle=False, num_workers=workers)
```

Произведем обучение параметров.

```
train_model = True
epochs = 50
epochs_nin = 100

lr = 0.004
lr_nin = 0.01
lr_scale = 0.5

momentum = 0.9

print_step = 5

deep_batch_size = 10
deep_num_classes = 10
deep_overshoot = 0.02
deep_max_iters = 50

deep_args = [deep_batch_size, deep_num_classes, deep_overshoot, deep_max_iters]
if not os.path.isdir('weights/deepfool'): os.makedirs('weights/deepfool', exist_ok=True)
if not os.path.isdir('weights/fgsm'): os.makedirs('weights/fgsm', exist_ok=True)
```

Загрузим и оценим стойкость модели Network-In-Network Model к FGSM и DeepFool атакам на основе датасета CIFAR-10.

```
fgsm_eps = 0.2
model = Net().to(device)
model.load_state_dict(torch.load('weights/clean/cifar_nin.pth', map_location=torch.device('cpu')))
evaluate_attack('cifar_nin_fgsm.csv', 'results', device, model, cifar_loader_test, cifar_min, cifar_max, fgsm_eps, is_fgsm=True)
print('')
evaluate_attack('cifar_nin_deepfool.csv', 'results', device, model, cifar_loader_test, cifar_min, cifar_max, deep_args, is_fgsm=False)
if device.type == 'cuda': torch.cuda.empty_cache()

FGSM Test Error : 81.29%
FGSM Robustness : 1.77e-01
FGSM Time (All Images) : 0.67 s
FGSM Time (Per Image) : 67.07 us

DeepFool Test Error : 93.76%
DeepFool Robustness : 2.12e-02
DeepFool Time (All Images) : 185.12 s
DeepFool Time (All Images) : 185.11 ms
```

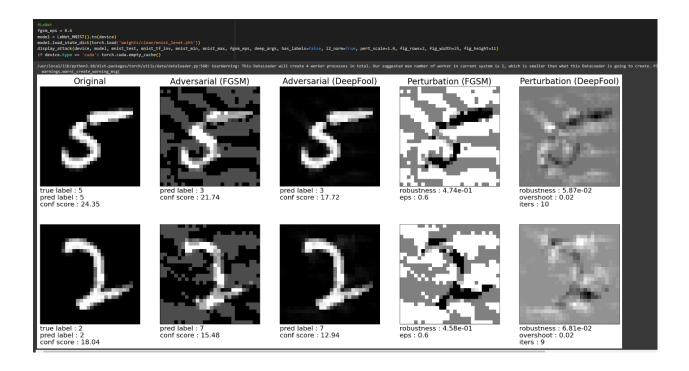
Загрузим и оценим стойкость модели LeNet к FGSM и DeepFool атакам на основе датасета CIFAR-10.

```
fgsm_eps = 0.1
model = LeNet_CIFAR().to(device)
model.load_state_dict(torch.load('weights/clean/cifar_lenet.pth', map_location=torch.device('cpu')))
evaluate_attack('cifar_lenet_fgsm.csv', 'results', device, model, cifar_loader_test, cifar_min, cifar_max, fgsm_eps, is_fgsm=True)
print('')
evaluate_attack('cifar_lenet_deepfool.csv', 'results', device, model, cifar_loader_test, cifar_min, cifar_max, deep_args, is_fgsm=False)
if device.type == 'cuda': torch.cuda.empty_cache()

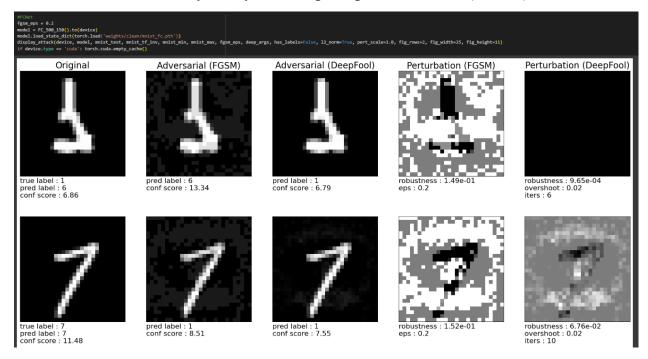
FGSM Test Error : 91.71%
FGSM Robustness : 8.90e-02
FGSM Time (All Images) : 0.40 s
FGSM Time (Per Image) : 40.08 us

DeepFool Tost Error : 87.81%
DeepFool Time (All Images) : 73.27 s
DeepFool Time (All Images) : 73.27 s
DeepFool Time (Per Image) : 7.33 ms
```

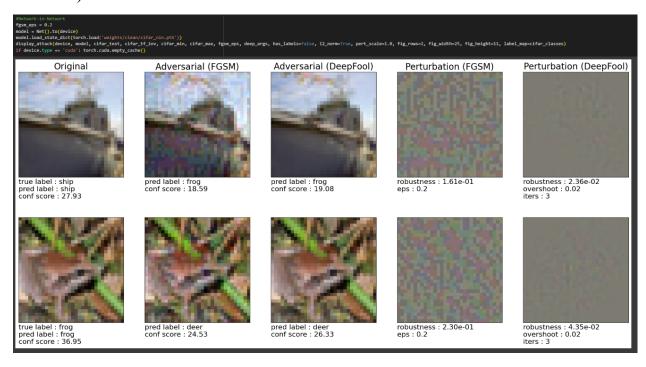
Выполним оценку атакующих примеров для сетей (LeNet).



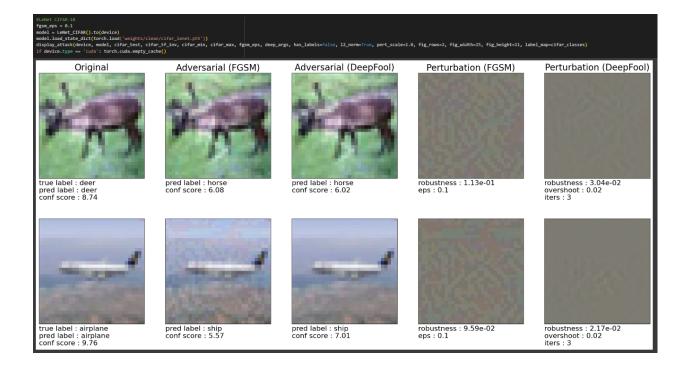
### Выполним оценку атакующих примеров для сетей (FCNet).



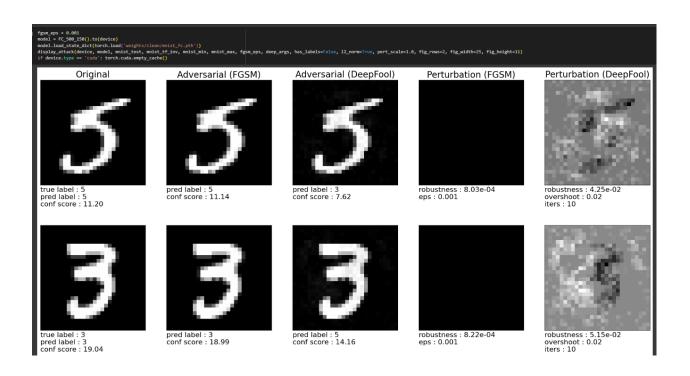
Выполним оценку атакующих примеров для сетей (Network-in-Network).

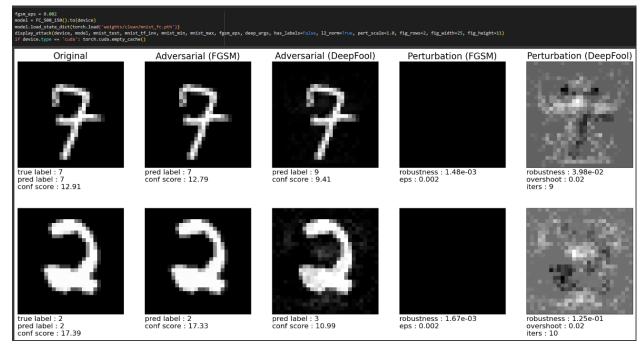


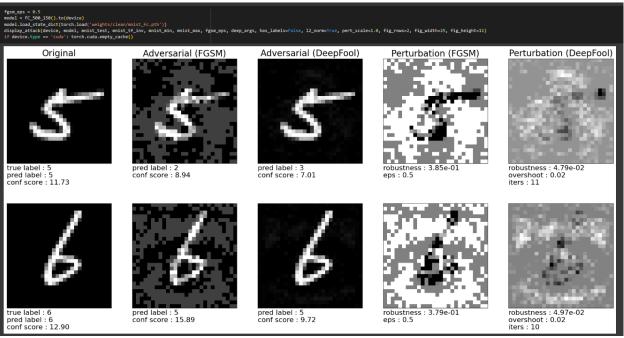
### Выполним оценку атакующих примеров для сетей (LeNet CIFAR-10).

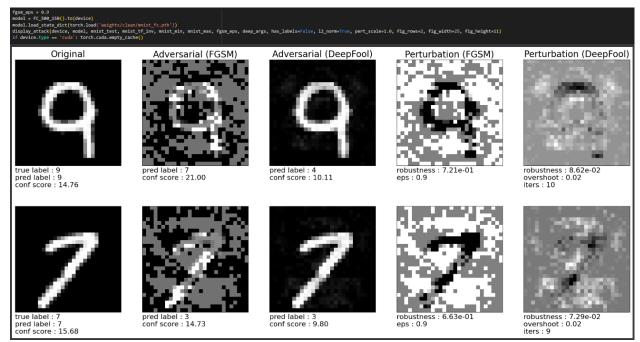


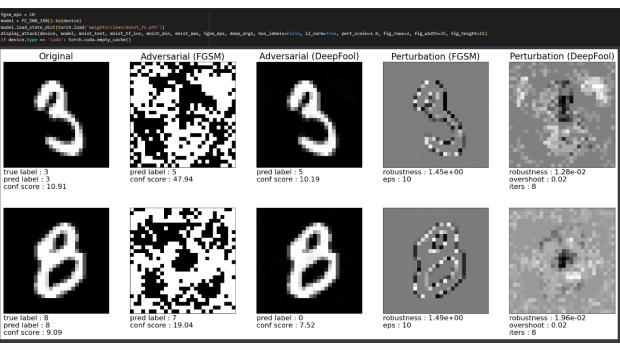
## Отражаем отличия для fgsm eps=(0.001, 0.02, 0.5, 0.9, 10).



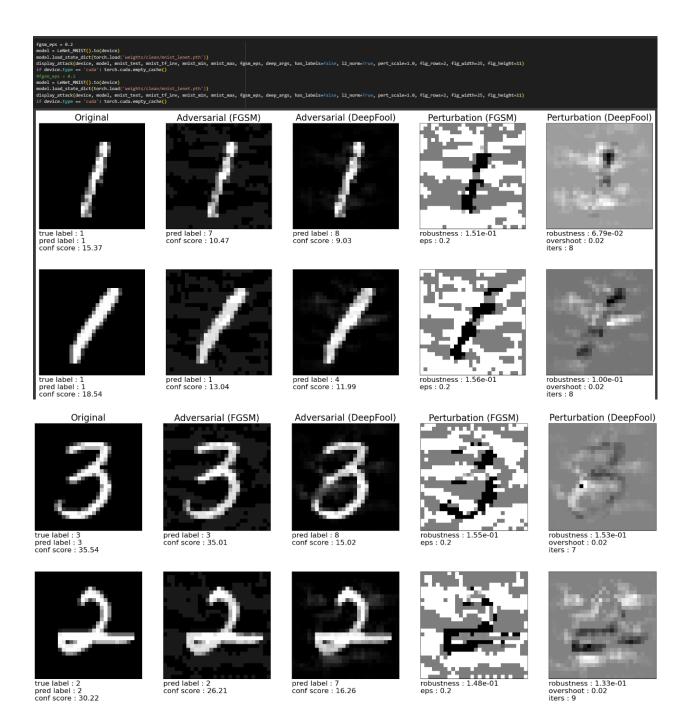


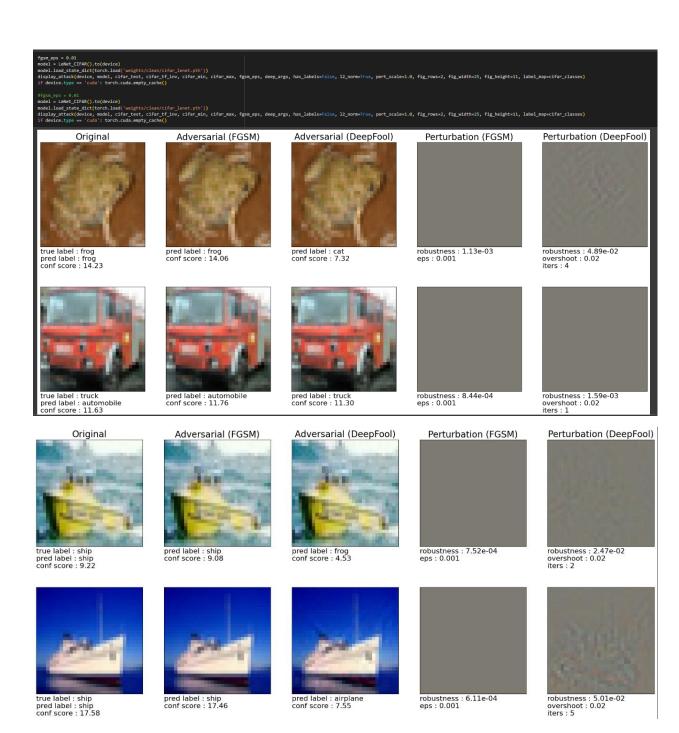




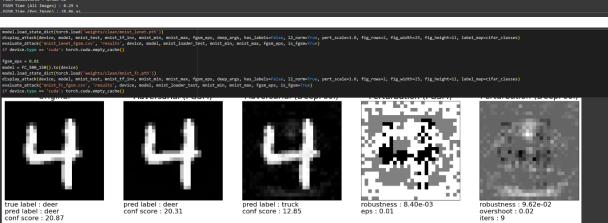


Выявим закономерность/обнаружим отсутсвие влияния параметра eps для сетей FC LeNet на датасете MNIST, NiN LeNEt на датасете CIFAR.





true label : truck pred label : truck conf score : 20.88 pred label : truck conf score : 20.16 robustness: 8.26e-03 eps: 0.01 robustness : 5.09e-02 overshoot : 0.02 iters : 9 pred label : ship conf score : 15.47



pred label : ship conf score : 12.68



true label : bird pred label : bird conf score : 20.10

true label : deer pred label : deer conf score : 18.57

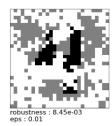
pred label : bird conf score : 19.60

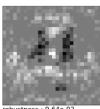
pred label : deer conf score : 17.98



pred label : bird conf score : 9.89

robustness : 8.22e-03 eps : 0.01





robustness : 9.82e-02 overshoot : 0.02 iters : 8

robustness : 9.64e-02 overshoot : 0.02 iters : 10

```
# NiN

fgsm_eps = 0.1

model = Net().to(device)

model.load_state_dict(torch.load('weights/clean/cifar_nin.pth', map_location=torch.device('cpu')))

evaluate_attack('cifar_lenet_nin.csv', 'results', device, model, cifar_loader_test, cifar_min, cifar_max, fgsm_eps, is_fgsm=True)

if device.type == 'cuda': torch.cuda.empty_cache()

print('')

#LeNet

fgsm_eps = 0.1

model = LeNet_CIFAR().to(device)

model.load_state_dict(torch.load('weights/clean/cifar_lenet.pth', map_location=torch.device('cpu')))

evaluate_attack('cifar_lenet_fgsm.csv', 'results', device, model, cifar_loader_test, cifar_min, cifar_max, fgsm_eps, is_fgsm=True)

if device.type == 'cuda': torch.cuda.empty_cache()

FGSM Test Error : 9.28X

FGSM Robustness : 8.93e=06

FGSM Time (All Image) : 141.14 us

FGSM Time (Per Image) : 141.14 us

FGSM Time (All Images) : 0.40 s

FGSM Time (Per Image) : 40.08 us
```

Вывод: Параметр ерѕ оказывает влияние на устойчивость сети. При этом, чем больше данный параметр, тем больше доля ошибки классификации и сети более уязвимы к атакам. Чем меньше значение ерѕ, тем более устойчивые к атакам становятся сети.